

IIC 2413 – Bases de Datos
 Interrogación 3 Rúbrica

Pregunta 1: External Merge Sort y Transacciones

a) [2 pts] Considere una relación de 3.000.000 páginas. Indique el número de fases y de I/O del External Merge Sort optimizado visto en clases cuando:

- En Buffer caben 11 páginas.

$$2 \cdot 3,000,000 \cdot \lceil 1 + \log_{10}(\lceil 3000000/11 \rceil) \rceil = 4,2 \cdot 10^7 \quad (1)$$

- En Buffer caben 101 páginas.

$$2 \cdot 3,000,000 \cdot \lceil 1 + \log_{100}(\lceil 3000000/101 \rceil) \rceil = 2,4 \cdot 10^7 \quad (2)$$

A medida que el buffer sigue creciendo el I/O decrece a $4 \cdot 3,000,000 = 1,2 \cdot 10^7$. para esto necesito aproximadamente $\sqrt{3,000,000} = 1733$ páginas en buffer. Si no escribo el último resultado es $3 \cdot 3,000,000 = 9 \cdot 10^7$.

b) [4 pts] Considerando el *schedule* del cuadro 1, tenemos que hay un ciclo entre T1 y T3, por lo tanto el *schedule* no es conflict serializable. En el caso de usar Strict-2PL tenemos dos casos:

- **Caso habitual:** Cuando llega T3, pide un *exclusive lock* sobre a y no se le otorga porque T1 tenía un *shared lock*. La transacción se congela y todo termina bien.
- Cuando llega T3 pasa lo mismo que lo anterior, pero si W(a) y W(c) no comparten recursos podría pasar que T3 siga con W(c). En ese caso se toma un *exclusive lock* y luego cuando T1 pida un *shared lock* de C este no será otorgado. Así tendríamos un deadlock.

También, si T3 hubiese venido de la forma W(c) y después W(a), sí o sí hubiesemos tenido un *deadlock*. Strict-2PL a veces puede generar *deadlocks* y esto es un problema para las bases de datos (que se resuelve mediante algoritmos que detectan y rompen los *deadlocks*). Cualquier respuesta entre las 3 es considerada correcta es correcta.

T1	T2	T3
R(a)	R(b)	W(a) W(c)
R(c)		
	R(c)	

Cuadro 1: schedule problema 2.

Pregunta 2: Logging

Undo Logging

Considerando el *schedule*:

Log Undo
<START T1>
<START T2>
<T1, a, 4>
<T2, b, 5>
<T2, c, 10>
<COMMIT T1>
<START CKPT (T2)>
<START T3>
<START T4>
<T3, a, 10>
<T2, b, 7>
<T4, d, 5>
<COMMIT T2>
<END CKPT>
<START T5>
<COMMIT T3>
<T5, e, -3>

- Hasta qué parte del *log* debo leer.
 - Dado que existe un **END CKPT**, se debe leer hasta el **START CKPT**.
- Qué variables deben deshacer sus cambios y cuál es el valor con el que quedarán.
 - T5 no está marcada con commit, por lo que por la línea <T5, e, -3> indica que debemos hacer que **e** vuelva a ser -3. Por la misma razón, la línea <T5, d, 5> nos indica que **d** debe volver a ser 5.
- Qué variables (de las que aparecen en el *log*) no son cambiadas en el proceso.
 - No se debe hacer *undo* de ninguna otra transacción, por lo que las variables **a**, **b** y **c** no son tocadas.

Redo Logging

Considerando el *schedule*:

Log Redo
<START T1>
<T1, a, 1>
<COMMIT T1>
<START T2>
<T2, b, 2>
<T2, c, 3>
<COMMIT T2>
<START T3>
<T3, a, 10>
<START CKPT (T3)>
<T3, d, 23>
<START T4>
<END CKPT>
<COMMIT T3>
<T4, e, 11>

- Desde qué parte del *log* debo comenzar el proceso de *redo*.
 - Dado que existe un **END CKPT**, debo leer hasta el **<START T3>**, que es la transacción más antigua que se señala en el **START CKPT**.
- Qué variables deben rehacer sus cambios y cuál es el valor con el que quedarán.
 - Tenemos la certeza de que T1 y T2 están guardadas en disco, porque tenemos la presencia de un **END CKPT**. fuera de esas transacciones, debemos rehacer todas las otras transacciones que están marcadas con **COMMIT**. En este caso es sólo T3. Por lo que **<T3, a, 10>** nos indica que debemos rehacer **a** al valor 10 y **<T3, d, 23>** nos indica que d debe rehacer **d** a 23.
- Qué variables (de las que aparecen en el *log*) no son cambiadas en el proceso.
 - Continuando con el proceso anterior, T4 no está marcado con commit, por lo que **e** no se debe tocar. T4 debe ser marcada con **ABORT** en el proceso. **b** y **c** tampoco son cambiadas en el proceso. Lo cambios efectuados a la variable **a** debido a T1 tampoco deben ser realizados de nuevo.
- Si no hubiesemos encontrado la línea **<END CKPT>**, ¿desde qué parte del *log* debería comenzar el proceso de *redo*?.
 - Debemos encontrar sí o sí un **<END CKPT>**. Así que como no hay otro se debe leer el *log* entero.

Pregunta 3: MongoDB

Una respuesta a los procedimientos es:

- [1.5 pts] Entregue el número de “Me gusta” que suman todos los fotogramas que en su descripción tengan el texto “#Trekking” y que no tengan el texto “Cerro La Cruz”.

```
var cursor = db.fi3.find({$text: {$search: "\"#Trekking\" -\"Cerro La Cruz\""}});
var suma_likes = 0;
cursor.forEach(
  (fotograma) => {
    var fid = fotograma.fid;
    var cursor2 = db.ui3.find({"me_gusta": fid});
```

```

        cursor2.forEach(
            (usuarios_like) => {
                suma_likes += 1;
            }
        )
    }
)
print(suma_likes);

```

- [2 pts] Imprima el identificador de cada usuario seguido de las URL de todos sus fotogramas.

```

var cursor = db.ui3.find({});
cursor.forEach(
    (usuario) => {
        var uid = usuario.uid;
        print("ID de Usuario: " + uid);
        var cursor2 = db.fi3.find({"posteadada_por": uid});
        cursor2.forEach(
            (fotograma) => {
                print(fotograma.fotograma);
            }
        )
    }
)

```

- [2.5 pts] Imprima el identificador de cada usuario junto al número total de “Me gusta” que ha recibido. Esto es, sumar los “Me gusta” de cada uno de sus fotogramas.

```

var cursor = db.fi3.find({});
var users_likes = {};
cursor.forEach(
    (fotograma) => {
        var fid = fotograma.fid;
        var uid = fotograma["posteadada_por"];
        var cursor2 = db.ui3.find({"me_gusta": fid});
        if (!users_likes[uid]) {
            users_likes[uid] = 0;
        }
        cursor2.forEach(
            (usuarios_like) => {
                users_likes[uid] += 1;
            }
        )
    }
)
printjson(users_likes);

```

Bonus [0.6 pts] Mencione 6 cerros que pertenecen a la Sierra de San Ramón.

- Cerro Provincia
- Cerro La Cruz

- Cerro San Ramón
- Cerro Punta Damas
- Cerro Morro del Tambor
- Cerro Minilla